Comparaison de modèles génératifs : WGAN-GP vs Score-based Generative Models via SDE

Berat DERIN
Julian GRALL
Master 2 ISIFAR – Université Paris-Cité

Avril 2026

Résumé

Ce rapport compare deux approches de modélisation générative sur des distributions 2D synthétiques : le Wasserstein GAN avec Gradient Penalty (WGAN-GP) et les Score-based Generative Models (SGM) fondés sur des équations différentielles stochastiques. Nous concevons trois jeux de données mettant en évidence les forces et faiblesses de chaque méthode : une distribution multimodale (8 gaussiennes), une structure fine continue (spirale) et une sous-variété (cercle). Nos résultats montrent que le SGM capture mieux la géométrie des données grâce à la diffusion progressive, tandis que le WGAN-GP distribue plus uniformément la masse entre les modes mais échoue à reproduire les structures fines. L'analyse révèle également que les métriques quantitatives comme le MMD peuvent être trompeuses et doivent être complétées par une évaluation visuelle.

1 Introduction

La modélisation générative vise à apprendre la distribution sous-jacente des données pour en générer de nouvelles. Deux familles de méthodes se distinguent par leurs fondements théoriques et leurs performances pratiques.

Les **Generative Adversarial Networks** (GANs) formulent la génération comme un jeu à deux joueurs entre un générateur et un discriminateur. Le WGAN-GP [1, 2] améliore la stabilité de l'entraînement en utilisant la distance de Wasserstein et une pénalité de gradient.

Les **Score-based Generative Models** (SGMs) [3] apprennent le gradient de la log-densité (le score) et génèrent des échantillons en inversant un processus de diffusion modélisé par une équation différentielle stochastique (SDE).

L'objectif de ce travail est de comparer empiriquement ces deux approches sur des données 2D synthétiques, en concevant des jeux de données qui mettent en évidence leurs différences de performance. Le choix de données de petite dimension permet une visualisation directe des résultats et une identification précise des faiblesses de chaque méthode.

2 Présentation des méthodes

2.1 WGAN-GP

Le WGAN [1] remplace la divergence de Jensen-Shannon des GANs classiques par la distance de Wasserstein-1 :

$$W_1(\mathbb{P}_r, \mathbb{P}_g) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x\sim\mathbb{P}_r}[f(x)] - \mathbb{E}_{x\sim\mathbb{P}_g}[f(x)] \tag{1}$$

où le supremum est pris sur les fonctions 1-Lipschitz, par la dualité de Kantorovich-Rubinstein.

Le WGAN-GP [2] enforce la contrainte de Lipschitz par une pénalité sur la norme du gradient du critique évalué sur des interpolations $\hat{x} = \epsilon x + (1-\epsilon)G(z)$ entre données réelles et générées :

$$\mathcal{L}_D = \underbrace{\mathbb{E}[D(G(z))] - \mathbb{E}[D(x)]}_{\text{estimation de } W_1} + \lambda \underbrace{\mathbb{E}\left[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2\right]}_{\text{gradient penalty}} \tag{2}$$

Le générateur minimise $\mathcal{L}_G = -\mathbb{E}[D(G(z))]$. On note que le critique D ne possède pas de sigmoid en sortie car il estime une distance, pas une probabilité.

2.2 Score-based Generative Model via SDE

Les SGMs [3] définissent un processus forward qui transforme progressivement les données en bruit via une SDE de type Variance Preserving (VP-SDE) :

$$dx = -\frac{1}{2}\beta(t)x\,dt + \sqrt{\beta(t)}\,dW_t \tag{3}$$

où $\beta(t) = \beta_{\min} + t(\beta_{\max} - \beta_{\min})$ est un schedule de bruit croissant linéairement. Ce processus admet une loi de transition gaussienne en forme close :

$$x_t \mid x_0 \sim \mathcal{N}(\alpha(t)x_0, \sigma^2(t)I), \quad \alpha(t) = e^{-\frac{1}{2}\int_0^t \beta(s)ds}, \quad \sigma^2(t) = 1 - \alpha^2(t) \tag{4}$$

Un réseau $s_\theta(x,t)$ est entraîné par denoising score matching. En pratique, on utilise la paramétrisation en prédiction de bruit (ϵ-prediction), où le réseau prédit le bruit ϵ ajouté aux données :

$$\mathcal{L} = \mathbb{E}_{t,x_0,\epsilon}\left[\|\epsilon_\theta(x_t,t) - \epsilon\|^2\right], \quad \epsilon \sim \mathcal{N}(0,I) \tag{5}$$

Le score se déduit par $\nabla_x \log p_t(x) = -\epsilon_\theta(x_t,t)/\sigma(t)$.

La génération se fait en inversant la SDE via le théorème d'Anderson. On utilise une approche DDPM : à chaque pas de temps, on reconstruit une estimation $\hat{x}_0$ puis on re-bruite vers le pas suivant :

$$\hat{x}_0 = \frac{x_t - \sigma(t)\epsilon_\theta(x_t,t)}{\alpha(t)}, \qquad x_{t-\Delta t} = \alpha(t-\Delta t)\hat{x}_0 + \sigma(t-\Delta t)\,z, \quad z \sim \mathcal{N}(0,I) \tag{6}$$

3 Conception des jeux de données

Nous concevons trois jeux de données 2D de 10 000 points chacun, ciblant chacun une faiblesse connue de l'une des méthodes.

3.1 8 Gaussiennes en cercle (distribution multimodale)

Huit gaussiennes isotropes ($\sigma = 0.05$) placées uniformément sur le cercle unité. Ce dataset teste le **mode collapse** des GANs : le générateur peut ignorer certains modes et concentrer sa masse sur un sous-ensemble. C'est un benchmark classique de la littérature sur les GANs.

3.2 Spirale (structure fine continue)

Une spirale d'Archimède bruitée ($\sigma = 0.05$) dont le rayon croît linéairement. Ce dataset teste la capacité à capturer une **structure géométrique fine et continue**. Les GANs tendent à produire des distributions plus diffuses tandis que les SGMs, grâce à la diffusion progressive, peuvent mieux préserver la structure.

3.3 Cercle unitaire (sous-variété)

Des points sur le cercle unité avec très peu de bruit ($\sigma = 0.02$). Les données vivent sur une sous-variété 1D de $\mathbb{R}^2$. Le score $\nabla_x \log p(x)$ **diverge** quand on s'approche de la variété car la densité est concentrée sur un ensemble de mesure nulle dans $\mathbb{R}^2$. C'est un défi théorique connu des SGMs.

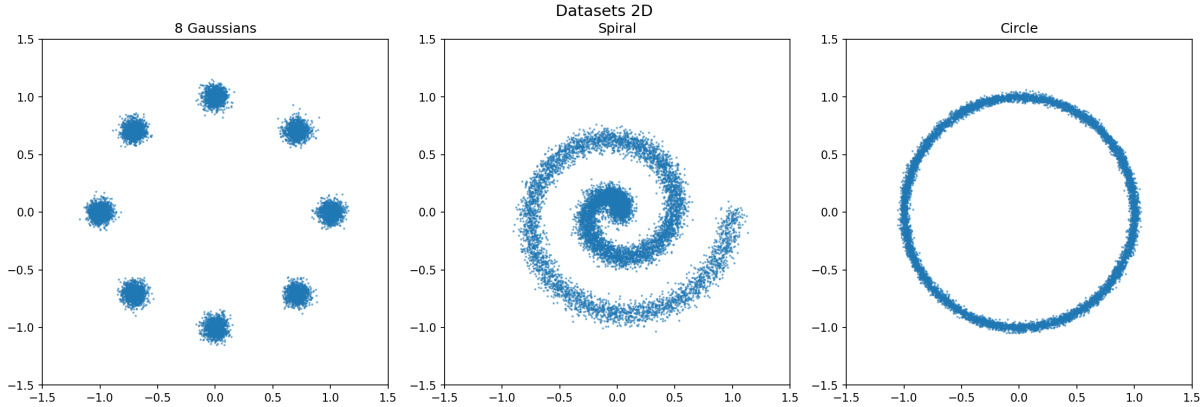

FIGURE 1 – Les trois jeux de données 2D synthétiques.

4 Détails d'implémentation

Toute l'implémentation est réalisée en PyTorch. Le code complet est fourni dans le notebook joint.

4.1 Architectures

	WGAN-GP	**SGM**
Générateur/Score net	MLP 3 couches	MLP 4 couches + time embedding
Entrée	$z \in \mathbb{R}^2$ (G) / $x \in \mathbb{R}^2$ (D)	$x \in \mathbb{R}^2$ + embedding de t
Sortie	$\mathbb{R}^2$ (G) / $\mathbb{R}$ (D)	$\mathbb{R}^2$ (bruit prédit)
Activation	ReLU	SiLU (Swish)
Dimension cachée	128	256
Injection du temps	–	Modulation additive

TABLE 1 – Architectures des réseaux.

Pour le SGM, le temps t est injecté via un embedding séparé (MLP à 2 couches) dont la sortie module les activations de la première couche cachée par addition. Cette approche est plus expressive qu'une simple concaténation de t aux entrées.

4.2 Hyperparamètres

	WGAN-GP	**SGM**
Optimiseur	Adam ($\beta_1 = 0, \beta_2 = 0.9$)	Adam (défaut)
Learning rate	10^{-4}	2×10^{-4}
Batch size	256	256
Époques	5000	5000
n_{critic}	5	–
λ_{GP}	10	–
$\beta_{\min}$, $\beta_{\max}$	–	0.1, 10.0
Pas de sampling	1 (forward pass)	2000 (Euler-Maruyama)
Gradient clipping	Non	Oui (norme max = 1.0)

Table 2 – Hyperparamètres d'entraînement.

Les betas d'Adam pour le WGAN-GP sont ceux recommandés dans [2]. Pour le SGM, le gradient clipping stabilise l'entraînement et $\beta_{\max} = 10$ (au lieu de 20 dans le papier original) réduit l'amplitude du bruit maximal, ce qui améliore la stabilité du sampling.

5 Résultats et analyse

5.1 Résultats visuels

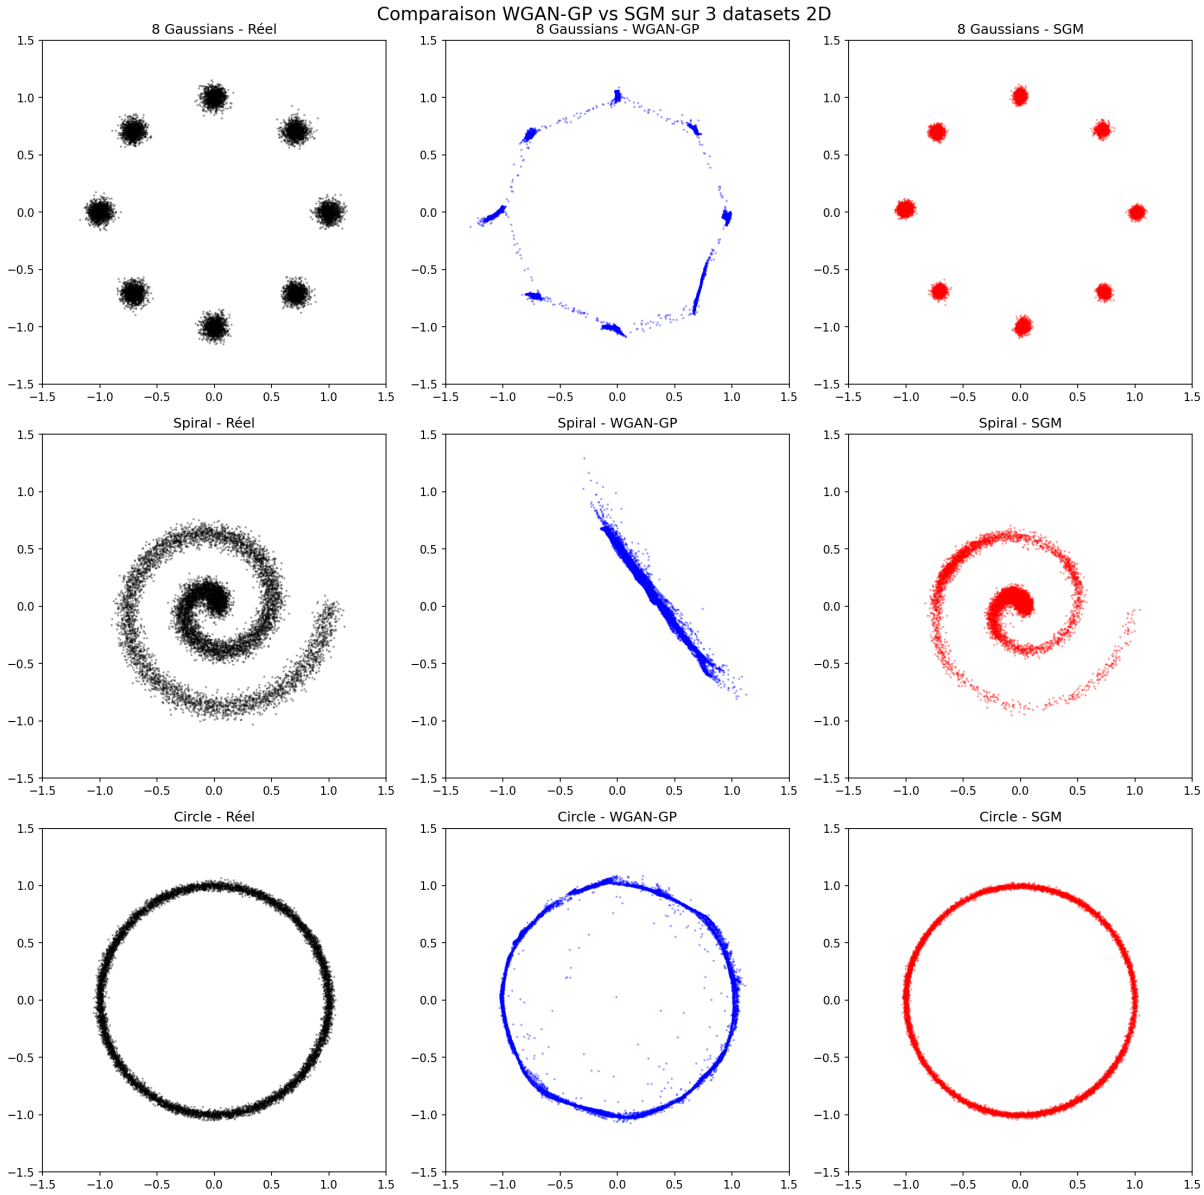

FIGURE 2 – Comparaison des échantillons générés. Chaque ligne correspond à un dataset, les colonnes montrent les données réelles, WGAN-GP et SGM respectivement.

L'inspection visuelle révèle des comportements distincts pour chaque méthode :

8 Gaussiennes. Les deux méthodes capturent les 8 modes. Cependant, le WGAN-GP produit des points parasites entre les modes, reliant les clusters par des "ponts" de densité. Le SGM produit des clusters plus nets et mieux séparés, mais avec des tailles inégales entre les modes.

Spirale. Le WGAN-GP échoue de manière spectaculaire : la spirale est réduite à un segment linéaire, illustrant un mode collapse sévère. Le SGM capture la forme de la spirale, notamment le centre et les premiers tours, mais perd les bras extérieurs les plus fins.

Cercle. Le WGAN-GP produit une forme déformée avec des concentrations de masse irrégulières. Le SGM reproduit un cercle reconnaissable avec une densité plus homogène, bien que légèrement non uniforme.

5.2 Estimation de densité par KDE

Les figures 3 et 4 montrent les densités estimées par noyau gaussien (KDE) pour chaque méthode.

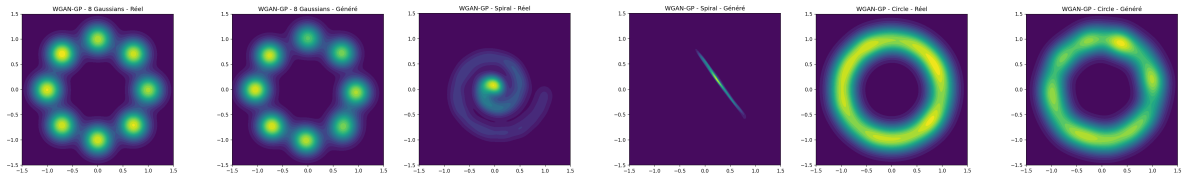

(a) 8 Gaussians (b) Spiral (c) Circle

FIGURE 3 – KDE des données réelles (gauche) vs générées par WGAN-GP (droite).

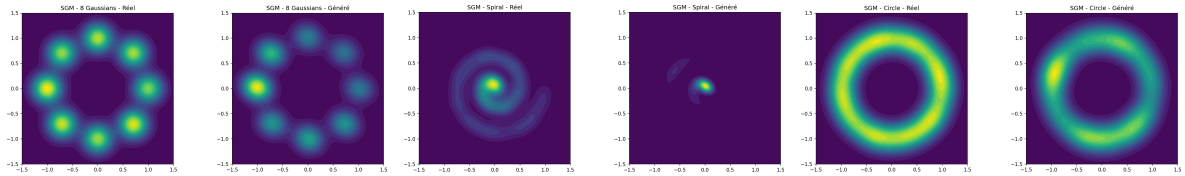

(a) 8 Gaussians (b) Spiral (c) Circle

FIGURE 4 – KDE des données réelles (gauche) vs générées par SGM (droite).

5.3 Métriques quantitatives : MMD

Le Maximum Mean Discrepancy (MMD) [4] mesure la distance entre deux distributions dans un espace de Hilbert à noyau reproduisant. Nous utilisons un noyau gaussien multi-bandwidth (bandwidths : 0.01, 0.05, 0.1, 0.5, 1.0) pour plus de robustesse.

Dataset	**MMD (WGAN-GP)**	**MMD (SGM)**	**Meilleur**
8 Gaussians	0.0130	0.0275	WGAN-GP
Spirale	0.1686	0.0668	SGM
Cercle	0.0037	0.0161	WGAN-GP

TABLE 3 – Maximum Mean Discrepancy (multi-bandwidth). Plus bas = meilleur.

Observation critique. Le MMD donne le WGAN-GP meilleur sur 8 Gaussians et Circle, ce qui contredit l'évaluation visuelle. Cela s'explique par le fait que le MMD mesure une distance statistique *globale* : le WGAN-GP étale ses points dans les bonnes régions de l'espace, ce qui suffit pour un bon score MMD, même si la structure fine n'est pas respectée. Cette observation souligne que **le MMD seul est insuffisant** pour évaluer la qualité de modèles génératifs et doit être complété par une analyse visuelle et des métriques structurelles.

5.4 Couverture des modes (8 Gaussians)

On considère qu'un mode est couvert si au moins 1% des échantillons générés tombent dans un rayon de 0.2 autour de son centre.

Méthode	Modes couverts	Écart-type des comptes
WGAN-GP	8/8	89.4
SGM	8/8	569.1

TABLE 4 – Couverture des modes sur le dataset 8 Gaussians.

Les deux méthodes couvrent les 8 modes. Cependant, le WGAN-GP distribue la masse de manière remarquablement uniforme (écart-type de 89 entre les comptes par mode), tandis que le SGM présente un fort déséquilibre (écart-type de 569), certains modes recevant jusqu'à trois fois plus de points que d'autres.

5.5 Stabilité de l'entraînement

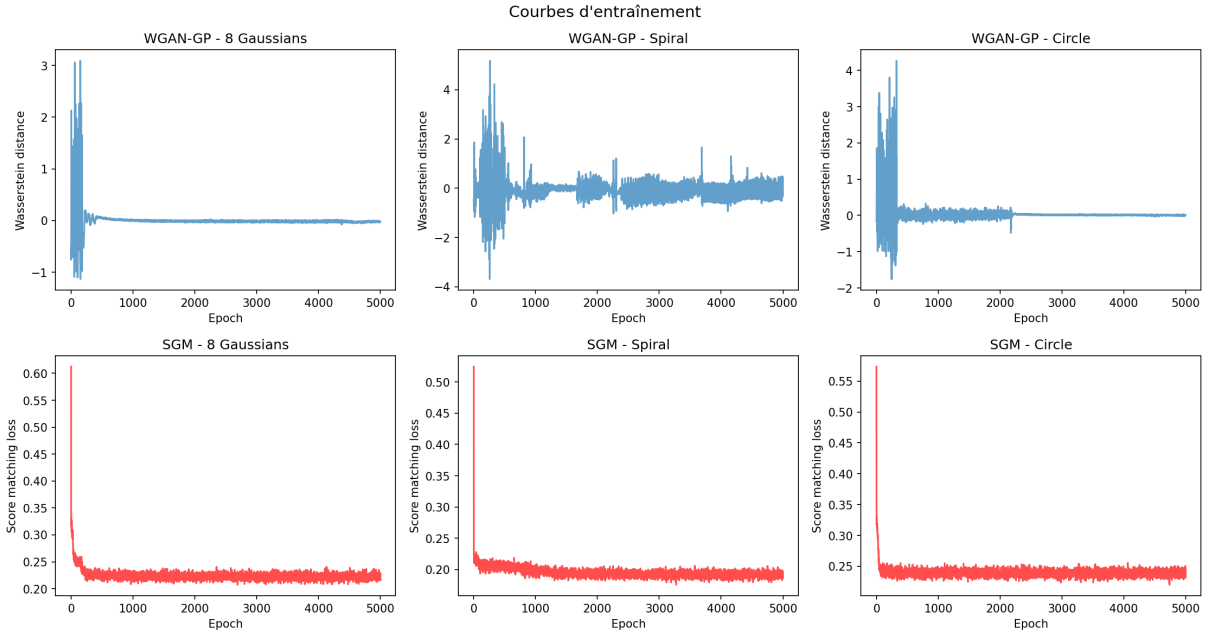

FIGURE 5 – Courbes d'entraînement. Haut : distance de Wasserstein estimée (WGAN-GP). Bas : loss de score matching (SGM).

Les courbes d'entraînement révèlent un contraste important en termes de stabilité. La distance de Wasserstein du WGAN-GP converge vers zéro mais reste **bruitée tout au long de l'entraînement**, avec des pics fréquents, en particulier sur le dataset Spiral. Cette instabilité est inhérente à l'entraînement adversarial, où le critique et le générateur s'opposent continuellement.

À l'inverse, la loss du SGM converge **rapidement** (en ∼500 époques) et reste **stable** ensuite. Le SGM ne souffre pas de l'instabilité adversariale car son entraînement se réduit à une simple régression (prédiction du bruit ajouté). C'est un avantage pratique majeur : le SGM est plus facile à entraîner et nécessite moins de tuning d'hyperparamètres.

6 Discussion

Nos résultats mettent en lumière plusieurs différences fondamentales entre les deux approches.

Fidélité structurelle vs couverture statistique. Le SGM reproduit mieux la géométrie des distributions (spirale, cercle) grâce à son processus de débruitage progressif : en inversant la SDE pas à pas, il reconstruit la structure des données de manière incrémentale. Le WGAN-GP, qui doit apprendre un mapping direct du bruit vers les données en un seul forward pass,

a plus de mal avec les structures fines. Cependant, le WGAN-GP distribue plus uniformément la masse entre les modes, probablement parce que le critique pénalise globalement les écarts de distribution.

Limites du MMD comme métrique d'évaluation. Le MMD favorise le WGAN-GP sur deux des trois datasets, en contradiction avec l'évaluation visuelle. Cela illustre un problème connu dans l'évaluation des modèles génératifs : les métriques scalaires peuvent être trompeuses. Une distribution qui couvre approximativement le bon support peut obtenir un meilleur MMD qu'une distribution qui capture précisément la structure mais avec quelques artefacts de sampling.

Stabilité de l'entraînement. Le SGM est nettement plus stable à entraîner, avec une convergence rapide et monotone. Le WGAN-GP, malgré le gradient penalty, reste sujet à des oscillations. En pratique, cela signifie que le SGM est plus facilement déployable et nécessite moins d'expertise pour le tuning.

Coût de génération. Un avantage notable du WGAN-GP est la vitesse de génération : un seul forward pass suffit, contre 2000 pas d'intégration pour le SGM. Pour des applications nécessitant la génération en temps réel, le WGAN-GP est significativement plus rapide.

Comportement sur les sous-variétés. Sur le dataset Circle, le SGM produit un cercle plus fidèle malgré le défi théorique de l'explosion du score sur les sous-variétés. Le ϵ-prediction et le clamping de la reconstruction $\hat{x}_0$ permettent de contourner partiellement ce problème. Le WGAN-GP déforme la sous-variété, suggérant que le mapping direct peine à apprendre des structures de codimension élevée.

7 Conclusion

Ce travail compare le WGAN-GP et les Score-based Generative Models sur trois distributions 2D synthétiques conçues pour exposer leurs forces et faiblesses respectives.

Le SGM se révèle supérieur en termes de fidélité structurelle et de stabilité d'entraînement. Sa capacité à capturer des géométries complexes (spirales, sous-variétés) est directement liée à son mécanisme de diffusion progressive, qui reconstruit les données pas à pas. Son principal inconvénient est le coût de génération élevé (2000 pas d'intégration) et un déséquilibre potentiel dans la couverture des modes.

Le WGAN-GP offre une génération rapide et une couverture uniforme des modes, mais souffre d'instabilité d'entraînement et d'une incapacité à reproduire les structures fines. Le mode collapse, bien que non observé sur le dataset multimodal, se manifeste de manière sévère sur la spirale.

Enfin, nos résultats soulignent l'importance de combiner métriques quantitatives et analyse visuelle pour évaluer les modèles génératifs, le MMD seul pouvant donner des conclusions trompeuses.

Références

[1] M. Arjovsky, S. Chintala, and L. Bottou. Wasserstein generative adversarial networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70, pages 214–223. PMLR, 2017.

[2] I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, and A. C. Courville. Improved training of Wasserstein GANs. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[3] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv :2011.13456*, 2020.

[4] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, and A. Smola. A kernel two-sample test. *Journal of Machine Learning Research*, 13 :723–773, 2012.

[5] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, 2020.